

Введение в искусственный интеллект. Современное компьютерное зрение Семинар 8. Генеративные состязательные сети

Бабин Д.Н., Иванов И.Е., Петюшко А.А.

кафедра Математической Теории Интеллектуальных Систем

13 апреля 2021 г.



① Вывод формул!



- 1 Вывод формул!
- 2 Условные состязательные генеративные сети



Энтропия для унитарного кодирования

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$.



Энтропия для унитарного кодирования

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$.
- Энтропия $H(p) = -\sum_{i=1}^n p_i \log p_i$



Энтропия для унитарного кодирования

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$.
- Энтропия $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса y_c :
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$



Энтропия для унитарного кодирования

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$.
- Энтропия $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса y_c :
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$
- В этом случае для $i = y_c$: $p_i \log p_i = 1 \cdot \log 1 = 1 \cdot 0 = 0$



Энтропия для унитарного кодирования

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$.
- Энтропия $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса y_c :
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$
- В этом случае для $i = y_c$: $p_i \log p_i = 1 \cdot \log 1 = 1 \cdot 0 = 0$
- А для $i \neq y_c$ воспользуемся правилом Лопиталя: $p_i \log p_i = \lim_{x \rightarrow 0} x \log x = \lim_{x \rightarrow 0} \frac{\log x}{1/x} = \lim_{x \rightarrow 0} \frac{(\log x)'}{(1/x)'} = \lim_{x \rightarrow 0} \frac{1/x}{-1/x^2} = -\lim_{x \rightarrow 0} x = 0$



Энтропия для унитарного кодирования

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$.
- Энтропия $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса y_c :
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$
- В этом случае для $i = y_c$: $p_i \log p_i = 1 \cdot \log 1 = 1 \cdot 0 = 0$
- А для $i \neq y_c$ воспользуемся правилом Лопиталя: $p_i \log p_i = \lim_{x \rightarrow 0} x \log x = \lim_{x \rightarrow 0} \frac{\log x}{1/x} = \lim_{x \rightarrow 0} \frac{(\log x)'}{(1/x)'} = \lim_{x \rightarrow 0} \frac{1/x}{-1/x^2} = -\lim_{x \rightarrow 0} x = 0$
- Таким образом, разобрали все случаи, и $H(p) = -\sum_{i=1}^n p_i \log p_i = 0$.



Неравенство Гиббса (1)

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$,
- $q = (q_1, \dots, q_n)$, $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$.



Неравенство Гиббса (1)

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$,
- $q = (q_1, \dots, q_n)$, $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$.



Неравенство Гиббса (1)

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$,
- $q = (q_1, \dots, q_n)$, $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$.

Неравенство Гиббса

$\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$ для любых распределений p, q , при этом равенство достигается только при $p = q$.

Доказательство.

- При $x > 0$ имеем $\log x \leq x - 1$, причем равенство достигается только при $x = 1$.



Неравенство Гиббса (1)

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$,
- $q = (q_1, \dots, q_n)$, $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$.

Неравенство Гиббса

$\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$ для любых распределений p, q , при этом равенство достигается только при $p = q$.

Доказательство.

- При $x > 0$ имеем $\log x \leq x - 1$, причем равенство достигается только при $x = 1$.
- Пусть I — множество индексов, в которых $p_i > 0$.



Неравенство Гиббса (1)

- Пусть $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$,
- $q = (q_1, \dots, q_n)$, $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$.

Неравенство Гиббса

$\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$ для любых распределений p, q , при этом равенство достигается только при $p = q$.

Доказательство.

- При $x > 0$ имеем $\log x \leq x - 1$, причем равенство достигается только при $x = 1$.
- Пусть I — множество индексов, в которых $p_i > 0$.
- Тогда $\sum_{i \in I} p_i \log q_i - \sum_{i \in I} p_i \log p_i = \sum_{i \in I} p_i \log \frac{q_i}{p_i} \leq \sum_{i \in I} p_i (\frac{q_i}{p_i} - 1) = \sum_{i \in I} q_i - \sum_{i \in I} p_i \leq 1 - \sum_{i \in I} p_i = 1 - 1 = 0$



Неравенство Гиббса (2)

Доказательство.

- В случае $p_i = 0$:
 - $p_i \log p_i = 0$ (см. ранее),



Неравенство Гиббса (2)

Доказательство.

- В случае $p_i = 0$:
 - $p_i \log p_i = 0$ (см. ранее),
 - Тогда $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$.



Доказательство.

- В случае $p_i = 0$:
 - $p_i \log p_i = 0$ (см. ранее),
 - Тогда $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$.
- Таким образом, $\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$, при этом равенство возможно только при $\frac{q_i}{p_i} = 1$ в случае $i \in I$,



Неравенство Гиббса (2)

Доказательство.

- В случае $p_i = 0$:
 - $p_i \log p_i = 0$ (см. ранее),
 - Тогда $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$.
- Таким образом, $\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$, при этом равенство возможно только при $\frac{q_i}{p_i} = 1$ в случае $i \in I$,
- Но тогда и $p_i = q_i = 0$, $i \notin I$. ■



Неравенство Гиббса (2)

Доказательство.

- В случае $p_i = 0$:
 - $p_i \log p_i = 0$ (см. ранее),
 - Тогда $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$.
- Таким образом, $\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$, при этом равенство возможно только при $\frac{q_i}{p_i} = 1$ в случае $i \in I$,
- Но тогда и $p_i = q_i = 0$, $i \notin I$. ■

Следствие. Максимальная энтропия для $p = (p_1, \dots, p_n)$, $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ равна: $H(p) = -\sum_{i=1}^n p_i \log p_i \leq -\sum_{i=1}^n p_i \log \frac{1}{n} = \log n \sum_{i=1}^n p_i = \log n$.



Определение

Функция близости (divergence) двух распределений, заданных на одном пространстве функций распределения S — это функция $D(\cdot||\cdot) : S \times S \rightarrow \mathbb{R}$, такая что:

- 1 $D(P||Q) \geq 0$ для всех $P, Q \in S$
- 2 $D(P||Q) = 0 \Leftrightarrow P = Q$



Функция близости Кульбака-Лейблера

Определение

Функция близости (divergence) двух распределений, заданных на одном пространстве функций распределения S — это функция $D(\cdot||\cdot) : S \times S \rightarrow \mathbb{R}$, такая что:

- 1 $D(P||Q) \geq 0$ для всех $P, Q \in S$
- 2 $D(P||Q) = 0 \Leftrightarrow P = Q$

Функция близости Кульбака-Лейблера

$$D_{KL}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$



Функция близости Кульбака-Лейблера

Определение

Функция близости (divergence) двух распределений, заданных на одном пространстве функций распределения S — это функция $D(\cdot||\cdot) : S \times S \rightarrow \mathbb{R}$, такая что:

- 1 $D(P||Q) \geq 0$ для всех $P, Q \in S$
- 2 $D(P||Q) = 0 \Leftrightarrow P = Q$

Функция близости Кульбака-Лейблера

$$D_{KL}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

Доказательство. $D_{KL}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = \sum_x p(x) \log p(x) - \sum_x p(x) \log q(x) \geq 0$,
при этом равенство достигается только при $P = Q$ (следствие из неравенства Гиббса). ■



Метрика на основе функции близости Йенсена-Шеннона (1)

Функция близости Йенсена-Шеннона

$$D_{JS}(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M), \text{ где } M = \frac{1}{2}(P + Q).$$



Метрика на основе функции близости Йенсена-Шеннона (1)

Функция близости Йенсена-Шеннона

$$D_{JS}(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M), \text{ где } M = \frac{1}{2}(P + Q).$$

Определение метрики

Функция $d : X \times X \rightarrow \mathbb{R}$ называется метрикой на пространстве X , если:

- ❶ $d(x, y) = 0 \Leftrightarrow x = y$,
- ❷ $d(x, y) = d(y, x)$,
- ❸ $d(x, z) \leq d(x, y) + d(y, z)$.



Метрика на основе функции близости Йенсена-Шеннона (1)

Функция близости Йенсена-Шеннона

$$D_{JS}(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M), \text{ где } M = \frac{1}{2}(P + Q).$$

Определение метрики

Функция $d : X \times X \rightarrow \mathbb{R}$ называется метрикой на пространстве X , если:

- 1 $d(x, y) = 0 \Leftrightarrow x = y$,
- 2 $d(x, y) = d(y, x)$,
- 3 $d(x, z) \leq d(x, y) + d(y, z)$.

Теорема

$\sqrt{D_{JS}(P||Q)}$ — метрика.

Метрика на основе функции близости Йенсена-Шеннона (2)

Доказательство.

$$\textcircled{1} \quad \sqrt{D_{JS}(P||Q)} = 0 \Leftrightarrow D_{JS}(P||Q) = 0 \Leftrightarrow D_{KL}(P||M) = D_{KL}(Q||M) = 0, P = Q = \frac{1}{2}(P + Q) \text{ (из свойств функции близости } D_{KL});$$

¹Endres D. M., Schindelin J. E. "A new metric for probability distributions". 2003.



Метрика на основе функции близости Йенсена-Шеннона (2)

Доказательство.

- ① $\sqrt{D_{JS}(P||Q)} = 0 \Leftrightarrow D_{JS}(P||Q) = 0 \Leftrightarrow D_{KL}(P||M) = D_{KL}(Q||M) = 0, P = Q = \frac{1}{2}(P + Q)$ (из свойств функции близости D_{KL});
- ② $\sqrt{D_{JS}(P||Q)} = \sqrt{\frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M)} = \sqrt{\frac{1}{2}D_{KL}(Q||M) + \frac{1}{2}D_{KL}(P||M)} = \sqrt{D_{JS}(Q||P)}$;

¹Endres D. M., Schindelin J. E. "A new metric for probability distributions". 2003.

Метрика на основе функции близости Йенсена-Шеннона (2)

Доказательство.

- ❶ $\sqrt{D_{JS}(P||Q)} = 0 \Leftrightarrow D_{JS}(P||Q) = 0 \Leftrightarrow D_{KL}(P||M) = D_{KL}(Q||M) = 0, P = Q = \frac{1}{2}(P + Q)$ (из свойств функции близости D_{KL});
- ❷ $\sqrt{D_{JS}(P||Q)} = \sqrt{\frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M)} = \sqrt{\frac{1}{2}D_{KL}(Q||M) + \frac{1}{2}D_{KL}(P||M)} = \sqrt{D_{JS}(Q||P)}$;
- ❸ А с неравенством треугольника здесь все действительно сложнее. За деталями — см. дополнительную литературу¹. ■

¹Endres D. M., Schindelin J. E. "A new metric for probability distributions". 2003.



GAN и оптимальное распределение D/G (1)

Если обозначить за p_g — распределение $G(z)$, то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как



GAN и оптимальное распределение D/G (1)

Если обозначить за p_g — распределение $G(z)$, то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x))]$$



GAN и оптимальное распределение D/G (1)

Если обозначить за p_g — распределение $G(z)$, то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x))]$$

Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$



GAN и оптимальное распределение D/G (1)

Если обозначить за p_g — распределение $G(z)$, то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x))]$$

Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

Доказательство. $V(D, G) = \mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x)) =$
 $\int_x (p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))) dx$



Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

Доказательство. Найдем точку экстремума функции $f(s) = p_{data} \log s + p_g \log(1 - s)$:



Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

Доказательство. Найдем точку экстремума функции $f(s) = p_{data} \log s + p_g \log(1 - s)$:

- $f'(s) = \frac{p_{data}}{s} - \frac{p_g}{1-s},$
- $f'(s) = 0 \Leftrightarrow p_{data}(1 - s) - p_g s = 0 \Leftrightarrow s = \frac{p_{data}}{p_{data} + p_g}.$



Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

Доказательство. Найдем точку экстремума функции $f(s) = p_{data} \log s + p_g \log(1 - s)$:

- $f'(s) = \frac{p_{data}}{s} - \frac{p_g}{1-s},$
- $f'(s) = 0 \Leftrightarrow p_{data}(1 - s) - p_g s = 0 \Leftrightarrow s = \frac{p_{data}}{p_{data} + p_g}.$

При этом $s = \frac{p_{data}}{p_{data} + p_g}$ — точка максимума функции $f(s)$ (можно проверить, например, что $\lim_{s \rightarrow 0+} f'(s) > 0, \lim_{s \rightarrow 1-} f'(s) < 0$).



Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

Доказательство. Найдем точку экстремума функции $f(s) = p_{data} \log s + p_g \log(1 - s)$:

- $f'(s) = \frac{p_{data}}{s} - \frac{p_g}{1-s},$
- $f'(s) = 0 \Leftrightarrow p_{data}(1 - s) - p_g s = 0 \Leftrightarrow s = \frac{p_{data}}{p_{data} + p_g}.$

При этом $s = \frac{p_{data}}{p_{data} + p_g}$ — точка максимума функции $f(s)$ (можно проверить, например, что $\lim_{s \rightarrow 0+} f'(s) > 0, \lim_{s \rightarrow 1-} f'(s) < 0$).

Таким образом, $\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}. \blacksquare$



GAN и оптимальное распределение D/G (3)

Пусть $C(G) = \max_D V(D, G)$

Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$



GAN и оптимальное распределение D/G (3)

Пусть $C(G) = \max_D V(D, G)$

Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

Доказательство.

- $$C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$$
$$\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$$



GAN и оптимальное распределение D/G (3)

Пусть $C(G) = \max_D V(D, G)$

Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

Доказательство.

- $C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$
 $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$
- $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} = \mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} - \mathbb{E}_{x \sim p_{data}} \log 2 =$
 $D_{KL}(p_{data} || \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$



GAN и оптимальное распределение D/G (3)

Пусть $C(G) = \max_D V(D, G)$

Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

Доказательство.

- $C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$
 $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$
- $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} = \mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} - \mathbb{E}_{x \sim p_{data}} \log 2 =$
 $D_{KL}(p_{data} \parallel \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$
- $\mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)} = D_{KL}(p_g \parallel \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$



GAN и оптимальное распределение D/G (3)

Пусть $C(G) = \max_D V(D, G)$

Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

Доказательство.

- $C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$
 $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$
- $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} = \mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} - \mathbb{E}_{x \sim p_{data}} \log 2 =$
 $D_{KL}(p_{data} \parallel \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$
- $\mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)} = D_{KL}(p_g \parallel \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$
- $\Rightarrow C(G) = D_{KL}(p_{data} \parallel \frac{p_{data}(x) + p_g(x)}{2}) + D_{KL}(p_g \parallel \frac{p_{data}(x) + p_g(x)}{2}) - 2 \log 2,$



Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

Доказательство.

- $\Rightarrow C(G) = 2D_{JS}(p_{data}||p_g) - \log 4 \geq -\log 4,$



Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

Доказательство.

- $\Rightarrow C(G) = 2D_{JS}(p_{data}||p_g) - \log 4 \geq -\log 4,$
- При этом $C(G) = -\log 4 \Leftrightarrow D_{JS}(p_{data}||p_g) = 0 \Leftrightarrow p_{data} = p_g. \blacksquare$



Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

Доказательство.

- $\Rightarrow C(G) = 2D_{JS}(p_{data}||p_g) - \log 4 \geq -\log 4,$
- При этом $C(G) = -\log 4 \Leftrightarrow D_{JS}(p_{data}||p_g) = 0 \Leftrightarrow p_{data} = p_g. \blacksquare$

Замечание. Таким образом, генератор G будет пытаться полностью повторять распределение исходных данных: $p_g = p_{data}$.



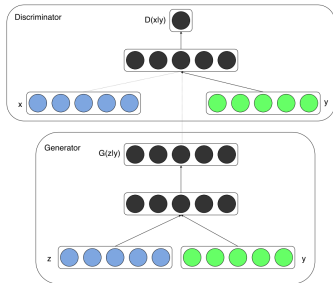
Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$





Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$




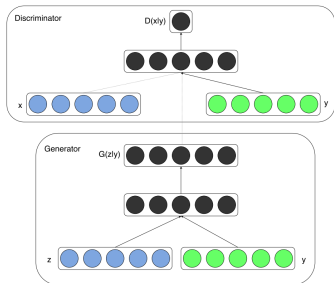
Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$



Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$




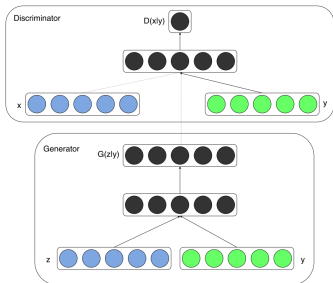
Ссылки для любознательных:

- 1 Image2Image Translation от Д. Михайлова



Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$



Ссылки для любознательных:

- 1 Image2Image Translation от Д. Михайлова
- 2 Image Generation от А. Иванюты



Спасибо за внимание!

